

De las primeras neuronas artificiales a ChatGPT: evolución de la inteligencia artificial moderna

Estado de la evolución de OpenAI comprobado a 5 de agosto de 2026.

Cómo encajan todas las ideas

La expresión **inteligencia artificial** no designa una única tecnología. Es el campo general que intenta construir sistemas capaces de realizar tareas asociadas con la inteligencia: percibir, razonar, aprender, comunicarse, planificar o actuar. El nombre quedó establecido como campo de investigación en el proyecto de Dartmouth de 1956. ¹

Dentro de ese campo se encuentra el **machine learning** o aprendizaje automático: en vez de escribir manualmente todas las reglas, se proporciona al sistema información o experiencia para que ajuste su comportamiento.

Dentro del machine learning se encuentra el **deep learning**, que utiliza redes neuronales con numerosas capas para aprender representaciones progresivamente más abstractas. Una red puede pasar, por ejemplo, de detectar bordes a identificar formas, objetos y finalmente conceptos completos. La revisión clásica de LeCun, Bengio y Hinton define precisamente el deep learning como el aprendizaje de representaciones con múltiples niveles de abstracción mediante capas sucesivas y retropropagación. ²

El mapa conceptual puede resumirse así:

Inteligencia artificial

- ↳ **Machine learning:** la máquina aprende a partir de datos
- ↳ **Deep learning:** aprende mediante redes neuronales profundas
- ↳ **Modelos de lenguaje:** aprenden regularidades del lenguaje
- ↳ **Transformers:** arquitectura especialmente eficaz para esos modelos
- ↳ **GPT:** transformers generativos preentrenados
- ↳ **ChatGPT:** producto conversacional construido sobre modelos GPT
- ↳ **Agentes:** modelos que razonan, seleccionan herramientas y ejecutan acciones

Una distinción fundamental es que **arquitectura, modelo y producto no son lo mismo**:

Concepto	Qué significa	Ejemplo
Arquitectura	Diseño matemático general de una red	Transformer
Modelo entrenado	Una arquitectura cuyos parámetros han aprendido de datos	GPT-3, GPT-4, GPT-5.6
Técnica de entrenamiento	Procedimiento utilizado para enseñar o adaptar el modelo	Preentrenamiento, fine-tuning, RLHF

Concepto	Qué significa	Ejemplo
Producto	Aplicación con interfaz, herramientas, memoria y medidas de seguridad	ChatGPT
Agente	Sistema que combina un modelo con planificación, herramientas y acciones	ChatGPT agent

Por tanto, **ChatGPT no es una arquitectura neuronal independiente**. Es un producto que, según el momento histórico, ha utilizado diferentes modelos, interfaces y herramientas.

Línea temporal esencial

La columna «tipo» evita mezclar la publicación de una idea científica con el lanzamiento de un modelo o de un producto comercial.

Año	Tipo	Hito	Qué cambió
1943	Investigación	Neurona de McCulloch y Pitts	Se mostró que redes de unidades neuronales simplificadas podían representar operaciones lógicas. ³
1956	Campo científico	Dartmouth	La inteligencia artificial quedó formulada como un área de investigación diferenciada. ¹
1958	Investigación y prototipo	Perceptrón de Rosenblatt	Apareció una unidad neuronal capaz de ajustar pesos para aprender clasificaciones sencillas. ⁴
1986	Investigación	Popularización de la retropropagación	Las redes multicapa pudieron aprender representaciones internas ajustando sus pesos según el error. ⁵
1990	Investigación	Redes recurrentes de Elman	Las redes empezaron a mantener un estado interno para procesar información temporal y secuencial. ⁶
1997	Investigación	LSTM	Sus mecanismos de memoria mitigaron el problema de conservar información durante secuencias largas. ⁷
2006–2012	Investigación	Renacimiento del deep learning	Mejores métodos, más datos y GPU hicieron viable entrenar redes profundas; AlexNet evidenció su eficacia en visión. ⁸
2014	Investigación	Sequence-to-sequence	Un LSTM codificaba una secuencia y otro generaba la secuencia de salida, impulsando la traducción neuronal. ⁹
2014	Investigación	Atención neuronal	El modelo dejó de depender exclusivamente de un único vector fijo y aprendió dónde mirar en la secuencia original. ¹⁰

Año	Tipo	Hito	Qué cambió
2017	Investigación	Transformer	Se eliminó la recurrencia y se construyó una arquitectura basada principalmente en atención, más paralelizable. ¹¹
2018	Investigación y modelo	Primer GPT	Se combinó un transformer generativo preentrenado con adaptación supervisada a tareas concretas. ¹²
2019	Modelo	GPT-2	La ampliación de escala produjo texto más coherente y capacidades rudimentarias sin entrenamiento específico para cada tarea. ¹³
2020	Investigación y modelo	GPT-3	Con 175.000 millones de parámetros, mostró aprendizaje <i>zero-shot</i> y <i>few-shot</i> mediante instrucciones y ejemplos en el propio prompt. ¹⁴
2022	Investigación y despliegue	InstructGPT y RLHF	El entrenamiento con demostraciones y preferencias humanas mejoró el seguimiento de instrucciones. ¹⁵
30 nov. 2022	Producto	ChatGPT	La tecnología se convirtió en un asistente conversacional accesible capaz de mantener diálogo y responder a preguntas sucesivas. ¹⁶
14 mar. 2023	Modelo y producto	GPT-4	Se introdujo un modelo más capaz que aceptaba texto e imágenes como entrada. ¹⁷
2023	Producto y API	Plugins y llamadas a funciones	Los modelos comenzaron a conectarse de forma estructurada con buscadores, bases de datos, servicios y APIs. ¹⁸
2024	Modelo	GPT-4o	Texto, visión y audio empezaron a procesarse de extremo a extremo dentro de un modelo multimodal más unificado. ¹⁹
2024	Modelo	OpenAI o1	Se consolidó el entrenamiento de modelos que dedican más computación a razonar antes de responder. ²⁰
2025	Modelos	GPT-4.5, o3 y o4-mini	Se hicieron visibles dos vías complementarias: ampliar el preentrenamiento y ampliar el razonamiento con herramientas. ²¹
17 jul. 2025	Producto	ChatGPT agent	ChatGPT pasó de responder a poder navegar, ejecutar código y realizar tareas mediante su propio entorno informático. ²²

Año	Tipo	Hito	Qué cambió
7 ago. 2025	Sistema de modelos	GPT-5	OpenAI presentó un sistema unificado capaz de seleccionar entre respuestas rápidas y razonamiento más profundo. ²³
2026	Modelos	GPT-5.4, GPT-5.5 y GPT-5.6	La evolución se centró en trabajo profesional completo, uso autónomo de herramientas, operación de software y flujos agénticos prolongados. ²⁴

Del perceptrón al deep learning

Las primeras neuronas artificiales

El problema: los primeros ordenadores ejecutaban instrucciones simbólicas, pero no existía un mecanismo claro para que aprendieran a reconocer patrones.

En 1943, Warren McCulloch y Walter Pitts propusieron una representación matemática extremadamente simplificada de una neurona: recibe varias señales y produce una salida cuando se alcanza una determinada condición. Mostraron que redes formadas por estas unidades podían describirse mediante lógica proposicional. ³

La intuición de una neurona artificial moderna es:

entradas × pesos → suma → función de activación → salida

Los **pesos** indican qué señales son importantes. Durante el aprendizaje, estos pesos se modifican.

La innovación posterior: el perceptrón de Rosenblatt convirtió esa unidad en un mecanismo de aprendizaje. Si cometía un error clasificando una entrada, modificaba sus pesos para reducir la probabilidad de repetirlo. El Mark I Perceptron fue construido como máquina física de reconocimiento de patrones. ⁴

Por qué fue importante: estableció la idea central de las redes neuronales: no programar directamente las reglas de reconocimiento, sino **aprenderlas ajustando conexiones**.

Qué permitía: clasificaciones sencillas, especialmente cuando las categorías podían separarse mediante una frontera lineal.

Cómo condujo al siguiente avance: una sola capa resultaba insuficiente para muchos problemas. Hacían falta capas internas que aprendiesen representaciones más complejas, pero también un método eficaz para entrenarlas.

Redes multicapa y retropropagación

Una red neuronal tradicional o **feed-forward** organiza las neuronas en capas:

entrada → capas ocultas → salida

La información avanza hacia delante. Cada capa transforma la representación recibida. En una imagen, las primeras capas pueden aprender contrastes; las siguientes, formas; y las últimas, objetos.

El problema: aunque las redes multicapa tenían mayor capacidad, no era sencillo saber cuánto debía modificarse cada conexión interna cuando el resultado final era incorrecto.

La innovación: la **retropropagación del error**, difundida decisivamente por Rumelhart, Hinton y Williams en 1986, calcula cómo contribuyó cada peso al error final y transmite esa información desde la salida hacia las capas anteriores. ⁵

Una forma intuitiva de entenderla es imaginar una cadena de montaje. Cuando el producto final tiene un defecto, se recorre la cadena hacia atrás para calcular qué ajuste corresponde a cada estación.

El entrenamiento repite un ciclo:

predicción → comparación con la respuesta correcta → cálculo del error → propagación hacia atrás → actualización de pesos

Por qué fue importante: las capas ocultas comenzaron a descubrir automáticamente características útiles, en vez de depender por completo de características diseñadas por programadores. ⁵

Qué permitió: reconocimiento de escritura, visión artificial, clasificación, reconocimiento de voz y, posteriormente, procesamiento del lenguaje.

Cómo condujo al deep learning: en teoría podían añadirse muchas capas, pero en la práctica el entrenamiento era caro e inestable. El progreso necesitaba más datos, mayor potencia de cálculo, mejores funciones de activación y técnicas de regularización.

El renacimiento del deep learning

Durante las décadas siguientes, las redes neuronales compitieron con otros métodos de machine learning. El gran cambio se produjo cuando convergieron tres factores:

más datos + GPU + mejores técnicas de entrenamiento

En 2012, AlexNet entrenó una red convolucional profunda con aproximadamente 60 millones de parámetros sobre 1,3 millones de imágenes, utilizando una implementación eficiente en GPU y obteniendo una mejora notable en ImageNet. ²⁵

El problema: los sistemas de visión y voz dependían en gran medida de características diseñadas manualmente y tenían dificultades para aprovechar conjuntos masivos de datos.

La innovación: las redes profundas podían aprender jerarquías completas de representaciones directamente a partir de los datos.

Por qué fue importante: demostró que aumentar la profundidad, los datos y la computación no era simplemente hacer más grande una tecnología antigua; podía producir saltos prácticos en rendimiento. La adopción se extendió desde visión hasta voz, audio y lenguaje. ²

Qué permitió: reconocimiento visual mucho más preciso, sistemas de voz, mejores traductores y el ecosistema tecnológico sobre el que más tarde se entrenarían los grandes modelos de lenguaje.

Cómo condujo al siguiente avance: imágenes y tablas pueden procesarse como entradas relativamente estáticas, pero el lenguaje es una secuencia: el significado de una palabra depende de lo que apareció antes y, en ocasiones, mucho antes.

De las redes secuenciales al Transformer

Redes recurrentes: una memoria que avanza palabra a palabra

Una red feed-forward ordinaria analiza cada entrada sin conservar necesariamente un recuerdo de las anteriores. Esto es problemático en una frase:

«El perro que perseguía a los gatos **estaba** cansado».

Para interpretar «estaba», hay que mantener información sobre «el perro» a través de varias palabras intermedias.

Las **redes neuronales recurrentes**, o RNN, incorporaron conexiones mediante las cuales el estado anterior vuelve a introducirse en el cálculo siguiente. Los trabajos sobre representación implícita del tiempo, como el de Elman en 1990, mostraron cómo un estado contextual podía capturar regularidades temporales y lingüísticas. ⁶

Intuitivamente:

palabra actual + memoria anterior → nueva memoria

El problema: los textos, el habla y las series temporales no son conjuntos de elementos independientes; el orden cambia el significado.

La innovación: una memoria interna que se actualizaba paso a paso.

Por qué fue importante: permitió modelar lenguaje, audio, escritura manuscrita y otros datos secuenciales.

Qué permitió: predicción de la siguiente palabra, reconocimiento de voz, generación de texto inicial y traducción neuronal.

Cómo condujo al siguiente avance: durante el entrenamiento, la señal de error debía recorrer numerosos pasos temporales. Podía hacerse cada vez más pequeña —gradiente desvanecido— o crecer sin control —gradiente explosivo—, dificultando el aprendizaje de dependencias largas.

LSTM: puertas que controlan la memoria

En 1997, Hochreiter y Schmidhuber presentaron **Long Short-Term Memory**, LSTM, para afrontar el deterioro de la señal de aprendizaje en secuencias largas. ⁷

Una LSTM mantiene una especie de cinta de memoria regulada por puertas:

- una puerta decide qué información nueva guardar;
- otra decide qué información olvidar;
- otra controla qué parte de la memoria utilizar como salida.

No guarda literalmente frases como un cuaderno. Mantiene vectores numéricos que condensan información relevante.

El problema: las RNN ordinarias olvidaban con facilidad relaciones alejadas en el tiempo.

La innovación: una ruta de memoria más estable y mecanismos aprendidos para escribir, conservar, eliminar y leer información.

Por qué fue importante: hizo mucho más viable aprender dependencias largas.

Qué permitió: mejoras en reconocimiento de voz, escritura, predicción temporal, generación de texto y traducción automática.

Cómo condujo al siguiente avance: las LSTM seguían procesando una secuencia de manera esencialmente ordenada. Además, comprimir una frase entera en una única representación seguía creando un cuello de botella.

Sequence-to-sequence y el cuello de botella

En 2014, el enfoque **sequence-to-sequence** utilizó una LSTM codificadora para transformar una frase en un vector fijo y otra LSTM decodificadora para generar la traducción. El método obtuvo resultados competitivos en traducción inglés-francés y mostró que una red podía aprender correspondencias completas entre secuencias. ⁹

La idea era semejante a esta:

frase original → resumen numérico → frase traducida

El problema: un vector de tamaño fijo debía contener toda la información de una frase, incluso si era larga.

La innovación: un sistema neuronal completo de codificación y decodificación.

Por qué fue importante: sustituyó numerosos componentes lingüísticos diseñados manualmente por un modelo entrenado de extremo a extremo.

Qué permitió: traducción, resumen, respuesta a preguntas y otras tareas de transformación de secuencias.

Cómo condujo al siguiente avance: el vector fijo funcionaba como intentar guardar un libro entero en una sola nota. La solución fue permitir que el decodificador consultara directamente diferentes partes del texto original.

Atención: mirar en el lugar adecuado

También en 2014, Bahdanau, Cho y Bengio plantearon explícitamente que el vector fijo era un cuello de botella. Su modelo aprendía a buscar de manera suave qué palabras de la frase original eran más relevantes para producir cada palabra traducida. ¹⁰

Al traducir:

«The black cat is sleeping»

para generar «gato», el modelo podía conceder más atención a «cat»; para generar «negro», a «black».

La atención asigna puntuaciones de relevancia y construye una combinación ponderada de la información disponible.

El problema: una única memoria comprimida perdía detalles, sobre todo en secuencias largas.

La innovación: acceso dinámico a todos los estados relevantes de la entrada.

Por qué fue importante: el modelo ya no tenía que recordar todo con la misma intensidad ni encerrarlo en un único resumen.

Qué permitió: traducciones más precisas y alineaciones aprendidas entre palabras o fragmentos.

Cómo condujo al Transformer: si la atención era tan efectiva, surgía una pregunta: ¿era realmente necesario mantener la complicada estructura recurrente?

Transformer: atención sin recurrencia

En junio de 2017 se publicó *Attention Is All You Need*. El trabajo presentó el **Transformer**, construido principalmente con mecanismos de atención y sin recurrencia ni convoluciones para la transformación de secuencias. ¹¹

Su elemento central es la **autoatención**: cada token de la secuencia calcula qué otros tokens son relevantes para interpretar su significado.

En:

«El banco junto al río no tenía dinero»

la palabra «banco» puede atender a «río» y reducir la interpretación financiera. En:

«El banco rechazó el préstamo»

puede atender a «préstamo» y adoptar el significado financiero.

Los transformers también emplean **atención multi-cabeza**. En vez de calcular una única relación, varias cabezas pueden especializarse en asociaciones diferentes: cercanía sintáctica, identidad de entidades, dependencia semántica o posición.

El problema: las RNN y LSTM procesaban los tokens sucesivamente, limitando la paralelización y dificultando algunas dependencias muy largas.

La innovación: todos los tokens podían relacionarse directamente mediante atención y gran parte del procesamiento podía ejecutarse en paralelo durante el entrenamiento.

Por qué fue importante: el Transformer resultó más paralelizable y necesitó menos tiempo de entrenamiento que los sistemas recurrentes comparados en el trabajo original. ¹¹

Qué permitió: modelos de lenguaje mucho mayores, entrenamiento con colecciones masivas de texto y una arquitectura que podía aplicarse posteriormente a texto, imágenes, audio y combinaciones multimodales.

Cómo condujo a GPT: el Transformer aportó la arquitectura. Faltaba definir cómo aprovechar enormes cantidades de texto sin etiquetar y cómo convertir ese aprendizaje general en capacidades útiles.

De GPT-1 a ChatGPT y GPT-4

Qué es realmente un modelo de lenguaje

Un **modelo de lenguaje** estima qué token resulta probable dadas las palabras o tokens anteriores. Durante el entrenamiento ve secuencias como:

«La capital de Francia es...»

y aprende a elevar la probabilidad de continuaciones coherentes.

Un **token** no tiene por qué coincidir con una palabra completa. Puede ser una palabra, parte de una palabra, un signo o un fragmento de código.

Predecir el siguiente token parece una tarea limitada, pero para hacerlo bien el modelo necesita capturar muchas regularidades: gramática, estilo, asociaciones conceptuales, estructuras documentales, código y numerosos patrones presentes en los datos. GPT-2, por ejemplo, se entrenó con el objetivo de predecir la siguiente palabra y mostró capacidades rudimentarias de traducción, resumen, comprensión y respuesta a preguntas sin entrenamiento específico para ellas. ¹³

Eso no significa que el modelo posea una base de datos literal de hechos ni que garantice respuestas verdaderas. Genera continuaciones plausibles según sus parámetros y el contexto disponible.

GPT-1: aprender primero, especializar después

En junio de 2018, OpenAI presentó el trabajo que inauguró la serie GPT. Combinó dos elementos:

Transformer + preentrenamiento generativo

El modelo se entrenaba primero con grandes cantidades de texto no etiquetado y después se adaptaba mediante entrenamiento supervisado a tareas concretas. ¹²

El problema: cada tarea de procesamiento del lenguaje requería grandes conjuntos de ejemplos etiquetados y modelos especializados.

La innovación: aprender una representación general del lenguaje antes de recibir etiquetas específicas.

Por qué fue importante: el conocimiento estadístico adquirido en el preentrenamiento podía transferirse a clasificación, inferencia, respuesta a preguntas y otras tareas.

Qué permitió: un único modelo base reutilizable en lugar de empezar desde cero para cada problema.

Cómo condujo a GPT-2: los resultados sugerían que ampliar el modelo y los datos podía aumentar las capacidades transferibles.

GPT-2: aparecen capacidades sin adaptación específica

GPT-2, anunciado el 14 de febrero de 2019, tenía 1.500 millones de parámetros y fue entrenado sobre ocho millones de páginas web para predecir la continuación del texto. ¹³

El problema: GPT-1 todavía dependía considerablemente del fine-tuning para rendir bien en cada tarea.

La innovación: ampliar modelo, datos y diversidad del preentrenamiento.

Por qué fue importante: comenzó a observarse que tareas como resumen, traducción o respuesta a preguntas podían emerger parcialmente del entrenamiento general, sin conjuntos específicos para cada una. ²⁶

Qué permitió: generación de párrafos más coherentes y aproximaciones iniciales al aprendizaje *zero-shot*.

Cómo condujo a GPT-3: reforzó la hipótesis de que la escala podía convertir un modelo de lenguaje en un sistema más general.

GPT-3: el prompt se convierte en interfaz de programación

GPT-3 fue presentado el 28 de mayo de 2020. Era un transformer autorregresivo de 175.000 millones de parámetros, frente a los 1.500 millones de GPT-2. ¹⁴

Su contribución más visible fue el **aprendizaje en contexto**:

- **Zero-shot:** se proporciona solamente una instrucción.
- **One-shot:** se proporciona un ejemplo.
- **Few-shot:** se proporcionan unos pocos ejemplos.
- **Fine-tuning:** se modifican internamente los parámetros con un conjunto de entrenamiento.

Los tres primeros no cambian los pesos del modelo. La tarea se especifica temporalmente dentro del prompt. GPT-3 fue evaluado de esta manera, sin actualizaciones de gradiente específicas para cada tarea. ²⁷

El problema: incluso los modelos preentrenados seguían requiriendo procesos técnicos de adaptación.

La innovación: muchas tareas podían describirse en lenguaje natural o mediante algunos ejemplos dentro del contexto.

Por qué fue importante: el texto pasó a funcionar como una interfaz de programación flexible.

Qué permitió: escritura asistida, clasificación, extracción, programación, transformación de textos y prototipos mediante API.

Cómo condujo al siguiente avance: predecir texto de internet no equivale a comprender la intención humana. Un modelo podía completar un prompt de forma plausible, pero ser poco útil, inventar información o no seguir correctamente una orden.

Las investigaciones sobre leyes de escala reforzaron además la idea de que el rendimiento de los modelos de lenguaje seguía relaciones relativamente predecibles con el tamaño del modelo, la cantidad de datos y la computación utilizada. ²⁸

InstructGPT y RLHF: de completar texto a ayudar

El preentrenamiento responde esencialmente a:

«¿Qué texto vendría probablemente después?»

Un asistente debe responder a otra cuestión:

«¿Qué respuesta resultaría más útil, adecuada y segura para la persona?»

InstructGPT utilizó humanos dentro del proceso de entrenamiento. Los evaluadores proporcionaron demostraciones de buenas respuestas y ordenaron varias respuestas del modelo según sus preferencias. Esa información se utilizó para ajustar GPT-3 mediante **reinforcement learning from human feedback**, RLHF. ¹⁵

El proceso puede simplificarse en tres pasos:

preentrenamiento → fine-tuning supervisado con demostraciones → optimización con preferencias humanas

El problema: los modelos base no estaban optimizados para seguir instrucciones ni alineados necesariamente con lo que deseaba el usuario.

La innovación: utilizar demostraciones y comparaciones humanas como señal de entrenamiento.

Por qué fue importante: incluso modelos más pequeños de InstructGPT fueron preferidos por los evaluadores frente al GPT-3 base de mayor tamaño, mostrando que el entrenamiento posterior podía importar tanto como la escala bruta. ¹⁵

Qué permitió: asistentes que obedecían instrucciones con mayor consistencia.

Cómo condujo a ChatGPT: una vez aprendido el comportamiento de asistente, el paso siguiente fue entrenarlo y presentarlo específicamente como interlocutor dentro de una conversación.

ChatGPT: el gran salto fue también de producto

ChatGPT fue lanzado como *research preview* el 30 de noviembre de 2022. Su formato de diálogo permitía preguntas sucesivas, correcciones, discusión de premisas y mantenimiento del contexto conversacional.

16

El nombre puede inducir a confusión:

- **GPT** designa una familia de modelos.
- **ChatGPT** es el producto y la experiencia conversacional.
- La primera versión pública de ChatGPT pertenecía a la línea GPT-3.5/InstructGPT, no a GPT-4, que todavía no se había lanzado.

El problema: las APIs y los prompts eran herramientas potentes, pero no constituían una experiencia accesible para el público general.

La innovación: una interfaz de chat combinada con entrenamiento para diálogo, memoria contextual de la conversación y despliegue iterativo.

Por qué fue importante: redujo drásticamente la barrera de entrada. Ya no era necesario programar ni conocer una API: bastaba conversar.

Qué permitió: tutoría, redacción, programación, lluvia de ideas, traducción, análisis y asistencia general.

Cómo condujo a GPT-4: el uso real expuso limitaciones de razonamiento, fiabilidad, control y percepción. El siguiente modelo debía mejorar capacidades y procesar más que texto.

GPT-4: mayor capacidad y entrada multimodal

GPT-4 fue presentado el 14 de marzo de 2023. OpenAI lo describió como un gran modelo multimodal que aceptaba imágenes y texto como entrada y generaba texto como salida. 17

El problema: los modelos anteriores tenían limitaciones en tareas complejas y estaban centrados principalmente en lenguaje textual.

La innovación: mayor escala y calidad de entrenamiento, mayor robustez y capacidad para interpretar entradas visuales.

Por qué fue importante: un mismo modelo podía analizar documentos, capturas, diagramas e imágenes junto con instrucciones escritas.

Qué permitió: análisis visual, comprensión de documentos, asistencia avanzada en programación y tareas profesionales más complejas.

Cómo condujo al siguiente avance: comprender imágenes seguía sin equivaler a mantener una conversación oral natural. Además, responder no era suficiente cuando una tarea exigía buscar información, ejecutar código o modificar un sistema externo.

De la multimodalidad a los agentes

GPT-4o: varios sentidos en un mismo modelo

Los sistemas multimodales iniciales podían funcionar como una cadena de componentes:

audio → transcripción → modelo textual → texto → sintetizador de voz

Ese proceso pierde parte de la entonación, las interrupciones, el ritmo y otros matices.

GPT-4o, anunciado en mayo de 2024, fue diseñado para procesar combinaciones de texto, audio, imagen y vídeo y generar texto, audio e imágenes. OpenAI lo presentó como un modelo entrenado de extremo a extremo a través de esas modalidades. ¹⁹

El problema: la multimodalidad basada en componentes independientes era lenta y podía descartar información entre etapas.

La innovación: integrar distintas modalidades dentro de un sistema neuronal más unificado.

Por qué fue importante: acercó la interacción a una conversación humana en tiempo real y permitió interpretar simultáneamente voz, imágenes y texto.

Qué permitió: conversación oral, traducción en tiempo real, análisis visual interactivo y experiencias accesibles.

Cómo condujo al siguiente avance: un modelo podía percibir mejor, pero las tareas difíciles seguían necesitando deliberación y comprobación.

Modelos de razonamiento: más computación al responder

La evolución de los modelos GPT iniciales se apoyó especialmente en ampliar el **preentrenamiento**. La serie o introdujo otra dimensión: ampliar la computación y el aprendizaje dedicado al **razonamiento durante la resolución**.

OpenAI o1-preview, lanzado en septiembre de 2024, fue entrenado para dedicar más tiempo a los problemas, probar estrategias y reconocer errores antes de producir una respuesta. ²⁰

GPT-4.5, presentado en febrero de 2025, hizo explícita la existencia de dos ejes complementarios:

Eje	Qué amplía	Fortalezas buscadas
Preentrenamiento	Datos, parámetros, optimización y conocimiento estadístico	Conocimiento general, intuición, fluidez
Razonamiento	Entrenamiento y computación dedicada a resolver el problema	Matemáticas, ciencia, código, planificación

OpenAI situó modelos como GPT-4.5 principalmente en el primer eje y modelos como o1 y o3 en el segundo. ²⁹

El problema: producir inmediatamente el token más probable no siempre basta para resolver correctamente una demostración matemática, depurar un programa o elaborar un plan de varios pasos.

La innovación: entrenar modelos para invertir más trabajo interno en la resolución y ajustar el esfuerzo a la dificultad.

Por qué fue importante: convirtió la computación de inferencia —la empleada después de recibir el prompt— en otra palanca de mejora.

Qué permitió: avances en matemáticas, programación, ciencias y tareas que requieren dividir un objetivo en subproblemas.

Cómo condujo a los agentes: razonar resulta mucho más útil cuando el sistema puede comprobar sus hipótesis con calculadoras, código, buscadores, archivos o aplicaciones.

Herramientas: del conocimiento interno a la consulta externa

Un modelo de lenguaje tiene tres limitaciones importantes:

1. Su conocimiento interno puede estar desactualizado.
2. Puede equivocarse en cálculos o inventar datos.
3. Generar texto no modifica el mundo externo.

La **llamada a funciones** permite proporcionar al modelo descripciones estructuradas de herramientas. El modelo decide cuándo utilizar una y genera argumentos en un formato que el programa puede ejecutar. En junio de 2023, OpenAI incorporó esta capacidad a versiones de GPT-3.5 y GPT-4, haciendo posible conectarlas de manera más fiable con APIs y servicios externos. ¹⁸

Por ejemplo:

usuario pregunta por el tiempo
→ el modelo decide llamar a una API meteorológica
→ recibe datos actuales
→ interpreta los resultados
→ redacta la respuesta

La idea académica de combinar **razonamiento y acción** había sido formalizada, entre otros enfoques, por ReAct en 2022: intercalar pasos de razonamiento con acciones sobre fuentes o entornos externos, actualizando el plan según los resultados obtenidos. ³⁰

OpenAI o3 y o4-mini, lanzados en abril de 2025, fueron entrenados no solo para utilizar herramientas, sino para razonar sobre **cuándo y cómo combinarlas**: búsqueda web, Python, archivos, análisis visual y generación de imágenes. ³¹

Agentes: de contestar a completar un objetivo

Un chatbot tradicional sigue un ciclo sencillo:

pregunta → respuesta

Un agente sigue un ciclo iterativo:

objetivo → plan → acción → observación → corrección → nueva acción → resultado

Un sistema agéntico suele incluir:

- un modelo capaz de interpretar el objetivo;
- memoria o estado de la tarea;
- herramientas;
- planificación;
- criterios de finalización;
- permisos y confirmaciones;
- mecanismos de revisión de resultados.

ChatGPT agent, lanzado el 17 de julio de 2025, integró navegación web, ejecución de código, análisis y operación mediante un ordenador virtual. Podía completar tareas de varios pasos, crear hojas de cálculo o presentaciones y solicitar al usuario autenticación o confirmación cuando fuese necesario. ³²

El problema: el usuario tenía que copiar información entre ChatGPT, navegador, terminal, calendario y otras aplicaciones.

La innovación: permitir que el sistema seleccionara herramientas, observara sus resultados y continuara trabajando.

Por qué fue importante: el modelo dejó de ser únicamente un generador de respuestas y pasó a convertirse en el motor de un proceso.

Qué permitió: investigación, análisis de datos, navegación, preparación de documentos y automatización de flujos profesionales.

Cómo condujo a las familias GPT-5: el razonamiento, la multimodalidad y las herramientas dejaron de tratarse como añadidos separados y comenzaron a unificarse dentro del sistema principal.

GPT-5 y la unificación de las líneas evolutivas

GPT-5 fue presentado el 7 de agosto de 2025 como un **sistema unificado**, con un modelo eficiente para la mayoría de las preguntas, un modelo de razonamiento más profundo y un mecanismo de enrutamiento que seleccionaba el tipo de respuesta más apropiado. ²³

Esto representa un cambio conceptual. La evolución dejó de consistir solamente en preguntar:

«¿Cuál es el modelo más grande?»

y pasó a preguntar:

«¿Qué combinación de razonamiento, herramientas, tiempo y recursos necesita esta tarea?»

En 2026, la progresión se aceleró:

GPT-5.4, lanzado el 5 de marzo, integró razonamiento, programación y flujos agénticos para trabajo profesional con documentos, hojas de cálculo, presentaciones, herramientas y entornos informáticos.

33

GPT-5.5, lanzado el 23 de abril, se orientó a tareas desordenadas y prolongadas: planificar, utilizar herramientas, comprobar el trabajo, manejar ambigüedad y continuar hasta completar un objetivo. 34

GPT-5.6, lanzado con disponibilidad general el 9 de julio de 2026, estructuró la familia en modelos como Sol, Terra y Luna, con distintos equilibrios entre capacidad, eficiencia y coste. A fecha de este informe es la generación oficial más reciente de la secuencia general GPT anunciada por OpenAI. 35

La dirección general puede resumirse así:

modelo que escribe

→ **modelo que conversa**

→ **modelo que ve y escucha**

→ **modelo que razona**

→ **modelo que usa herramientas**

→ **sistema que planifica y ejecuta trabajo**

Esta evolución también amplía los riesgos. Cuando un modelo solamente genera texto, un error produce una respuesta incorrecta. Cuando puede navegar, acceder a datos o realizar acciones, el mismo error puede tener consecuencias reales. OpenAI reconoce riesgos como las inyecciones de prompt, el acceso excesivo a información y las acciones no deseadas, por lo que los agentes incorporan permisos, supervisión y confirmaciones antes de determinadas operaciones. 36

La historia completa en una sola idea

Toda esta evolución puede entenderse como la resolución sucesiva de una cadena de limitaciones.

Limitación	Solución
Las reglas programadas manualmente no escalan	Machine learning
Una neurona simple solo aprende patrones limitados	Redes multicapa
No se sabía entrenar bien las capas ocultas	Retropropagación
Las redes poco profundas no captaban suficiente abstracción	Deep learning
Las redes estáticas no recordaban el orden	RNN
Las RNN olvidaban dependencias largas	LSTM
Una secuencia entera no cabía bien en un vector fijo	Atención
La recurrencia era lenta y difícil de paralelizar	Transformer
Cada tarea requería un modelo específico	Preentrenamiento
Adaptar el modelo requería numerosos ejemplos etiquetados	Aprendizaje en contexto

Limitación	Solución
Predecir texto no implicaba seguir intenciones	Fine-tuning de instrucciones y RLHF
Una API no era accesible para todo el mundo	ChatGPT
El texto no bastaba para representar el entorno	Multimodalidad
Responder deprisa no resolvía problemas complejos	Modelos de razonamiento
El conocimiento interno no era actual ni verificable	Herramientas y búsqueda
Generar una respuesta no completaba una tarea	Agentes

La conexión central es la siguiente:

Las primeras redes aprendían **una frontera de clasificación**.
 Las redes profundas aprendieron **representaciones jerárquicas**.
 Las RNN y LSTM aprendieron **secuencias y memoria temporal**.
 La atención aprendió **qué información era relevante**.
 El Transformer permitió hacer todo eso **a gran escala y en paralelo**.
 GPT convirtió el preentrenamiento en **conocimiento lingüístico reutilizable**.
 GPT-3 convirtió el prompt en **una interfaz para definir tareas**.
 InstructGPT y ChatGPT convirtieron el modelo en **un asistente conversacional**.
 GPT-4 y GPT-4o ampliaron la interacción a **imágenes, voz y otras modalidades**.
 Los modelos de razonamiento añadieron **deliberación antes de responder**.
 Las herramientas y los agentes transformaron el asistente en **un sistema capaz de actuar**.

El hilo conductor no es únicamente que los modelos tengan cada vez más parámetros. La evolución combina cinco dimensiones:

arquitectura + datos + computación + entrenamiento humano + herramientas

La arquitectura Transformer hizo viable la escala; el preentrenamiento acumuló patrones generales; el fine-tuning y el RLHF orientaron el comportamiento; la multimodalidad amplió la percepción; el razonamiento aumentó la profundidad de resolución; y las herramientas conectaron el modelo con información y acciones externas.

Por eso la transición más importante puede expresarse así:

La IA moderna ha pasado de reconocer patrones en datos aislados a mantener contexto, comprender varias modalidades, razonar sobre objetivos y coordinar acciones para completar tareas.

¹ Artificial Intelligence (AI) Coined at Dartmouth | Dartmouth
<https://home.dartmouth.edu/about/artificial-intelligence-ai-coined-dartmouth>

² Deep learning | Nature
<https://www.nature.com/articles/nature14539>

- 3 A logical calculus of the ideas immanent in nervous activity | Bulletin of Mathematical Biology | Springer Nature Link
<https://link.springer.com/article/10.1007/BF02478259>
- 4 Professor's perceptron paved the way for AI – 60 years too soon
https://news.cornell.edu/stories/2019/09/professors-perceptron-paved-way-ai-60-years-too-soon?utm_source=chatgpt.com
- 5 Learning representations by back-propagating errors | Nature
<https://www.nature.com/articles/323533a0>
- 6 Finding structure in time - ScienceDirect.com
https://www.sciencedirect.com/science/article/pii/036402139090002E?utm_source=chatgpt.com
- 7 Long Short-Term Memory | MIT Press Journals & Magazine
https://ieeexplore.ieee.org/abstract/document/6795963?utm_source=chatgpt.com
- 8 25 ImageNet Classification with Deep Convolutional Neural Networks
<https://proceedings.neurips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural->
- 9 [1409.3215] Sequence to Sequence Learning with Neural Networks
<https://arxiv.org/abs/1409.3215>
- 10 [1409.0473] Neural Machine Translation by Jointly Learning to Align and Translate
<https://arxiv.org/abs/1409.0473>
- 11 [1706.03762] Attention Is All You Need
<https://arxiv.org/abs/1706.03762>
- 12 cdn.openai.com
https://cdn.openai.com/research-covers/language-unsupervised/language_understanding_paper.pdf
- 13 26 Better language models and their implications | OpenAI
<https://openai.com/index/better-language-models/>
- 14 27 Language models are few-shot learners | OpenAI
<https://openai.com/index/language-models-are-few-shot-learners/>
- 15 Aligning language models to follow instructions | OpenAI
<https://openai.com/index/instruction-following/>
- 16 Introducing ChatGPT | OpenAI
<https://openai.com/index/chatgpt/>
- 17 GPT-4 | OpenAI
<https://openai.com/index/gpt-4-research/>
- 18 Function calling and other API updates | OpenAI
<https://openai.com/index/function-calling-and-other-api-updates/>
- 19 Hello GPT-4o | OpenAI
<https://openai.com/index/hello-gpt-4o/>
- 20 Introducing OpenAI o1 | OpenAI
<https://openai.com/index/introducing-openai-o1-preview/>
- 21 29 Introducing GPT-4.5 | OpenAI
<https://openai.com/index/introducing-gpt-4-5/>
- 22 32 36 Introducing ChatGPT agent: bridging research and action | OpenAI
<https://openai.com/index/introducing-chatgpt-agent/>

23 **Introducing GPT-5 | OpenAI**

<https://openai.com/index/introducing-gpt-5/>

24 33 **Introducing GPT-5.4 | OpenAI**

<https://openai.com/index/introducing-gpt-5-4/>

28 **[2001.08361] Scaling Laws for Neural Language Models**

<https://arxiv.org/abs/2001.08361>

30 **[2210.03629] ReAct: Synergizing Reasoning and Acting in Language Models**

<https://arxiv.org/abs/2210.03629>

31 **Introducing OpenAI o3 and o4-mini | OpenAI**

<https://openai.com/index/introducing-o3-and-o4-mini/>

34 **Introducing GPT-5.5 | OpenAI**

<https://openai.com/index/introducing-gpt-5-5/>

35 **GPT-5.6: Frontier intelligence that scales with your ambition | OpenAI**

<https://openai.com/index/gpt-5-6/>